

Hurtownia Danych

Analiza Katastrof Naturalnych

Źródła danych:

USGS Earthquake Catalog | EMDAT Emergency Events Database

Mateusz Stasiak, Daminika Dzeranhouskaya

Cel biznesowy

Celem projektu jest budowa hurtowni danych wspierającej decyzje firm ubezpieczeniowych i reasekuracyjnych w zakresie wyceny ryzyka sejsmicznego. Platforma integruje dane o parametrach fizycznych zdarzeń sejsmicznych (USGS) z danymi o ich zrealizowanych skutkach finansowych i humanitarnych (EMDAT), umożliwiając analizę, której żadne z tych źródeł nie dostarcza samodzielnie.

Dane EMDAT – straty w USD, koszty odbudowy, liczba ofiar i rannych – opisują **co się wydarzyło**, ale nie odpowiadają na pytanie **czy i kiedy może się powtórzyć**. Ubezpieczyciel operujący wyłącznie na danych o szkodach nie jest w stanie pełnie wnioskować na temat przyszłych ryzyk związanych z trzęsieniami ziemi. Dopiero połączenie szkód z parametrami sejsmicznymi – magnitudą, głębokością i odległością epicentrum – pozwala modelować prawdopodobieństwo i szacować oczekiwaną wartość przyszłych strat.

Źródła danych

USGS Earthquake Catalog

Baza danych prowadzona przez United States Geological Survey. Zawiera informacje o każdym zarejestrowanym zdarzeniu sejsmicznym od roku 1900. Częstotliwość aktualizacji danych w bazie pojawiają się zazwyczaj w ciągu kilku minut od zdarzenia (dane automatyczne), dane przeglądane przez człowieka (reviewed) trafiają do bazy w ciągu godzin do dni. Dostęp przez bezpłatne REST API, bez klucza i rejestracji.

Atrybut	Wartość
URL API	https://earthquake.usgs.gov/fdsnws/event/1/query
Format	CSV
Pokrycie	Globalny, 1900 – obecnie
Aktualizacja	Codziennie
Limit	Max 20 000 rekordów na zapytanie
Kluczowe pola	czas, szerokość/długość geogr., głębokość, magnituda, kraj, tsunami

EMDAT – Emergency Events Database

Baza prowadzona przez Centre for Research on the Epidemiology of Disasters (CRED) przy Uniwersytecie w Lowanium. Zawiera zagregowane dane o skutkach katastrof naturalnych i technologicznych od 1900 roku. Jest aktualizowana w trybie tygodniowym. Dostępna po bezpłatnej rejestracji jako eksport CSV/Excel.

Atrybut	Wartość
URL	https://www.emdat.be/
Format	CSV
Pokrycie	Globalny, wszystkie kontynenty, 1900 – obecnie
Aktualizacja	Co tydzień
Kluczowe pola	typ katastrofy, kraj, daty, ofiary, ranni, dotknięci, straty w USD

Integracja i modelowanie danych

Oba datasety nie posiadają wspólnego identyfikatora i charakteryzują się asymetryczną relacją (nie każdy wstrząs to katastrofa, a jedna katastrofa może składać się z wielu wstrząsów). Łączenie i modelowanie danych realizowane jest na trzech głównych płaszczyznach architektonicznych:

1. Dopasowanie algorytmiczne i Tabela Mostkowa (Bridge Table)

Dla każdego rekordu z EMDAT wyszukiwane są pasujące zdarzenia sejsmiczne z USGS na podstawie dwóch kryteriów:

- **Przestrzennego:** epicentrum wstrząsu (USGS) leży w promieniu $r = 100$ km od współrzędnych katastrofy (EMDAT).
- **Czasowego:** data wstrząsu mieści się w oknie czasowym do $T = 3$ dni przed wystąpieniem katastrofy.

Ponieważ jedno zdarzenie w EMDAT może zostać powiązane z wieloma wstrząsami z USGS (np. wstrząs główny oraz seria wstrząsów wtórnych), w hurtowni zastosowano bezfaktową tabelę mostkową (**Bridge_Disaster_Seismic**). Przechowuje ona pary kluczy obcych, skutecznie rozwiązując relację wiele-do-wielu (M:N) bez powielania danych o ofiarach i stratach.

2. Konstelacja Faktów (Fact Constellation Schema)

Aby uniknąć ogromnej liczby pustych wartości (NULL) dla wstrząsów, które nie wywołały ofiar, model zrezygnował z klasycznego schematu gwiazdy na rzecz konstelacji. Zbudowano dwie osobne tabele faktów:

- **FactSeismic** – przechowuje fizyczne parametry wstrząsów (magnituda, głębokość).
- **FactDisaster** – przechowuje konsekwencje humanitarne i ekonomiczne.

Obie tabele faktów są połączone przez wspólne wymiary, takie jak **DimDate** oraz **DimGeography**. Dzięki temu na warstwie raportowej (Power BI) można płynnie filtrować i analizować dane z obu źródeł jednocześnie – np. zestawiając roczne straty finansowe w danym kraju z całkowitą liczbą i siłą wstrząsów, jakie tam wystąpiły, niezależnie od tego, czy pojedynczy wstrząs trafił do bazy EMDAT.

3. Obsługa historyczności – SCD Typ 2 (Slowly Changing Dimensions)

Ponieważ integrowane dane obejmują ponad 100 lat historii (od 1900 roku), wymiar geograficzny (**DimGeography**) podlega zmianom w czasie. Granice państw ulegają przesunięciom, zmieniają się nazwy krajów, powołuje się nowe państwa, a ich populacja drastycznie rośnie (co bezpośrednio wpływa na skalę ofiar ludzkich w EMDAT). Aby zachować analityczną poprawność, wdrożono wymiar wolnozmieniający się Typu 2.

Przykład: trzęsienia ziemi z roku 1988 na terytorium dzisiejszej Rosji zostaną przypisane do historycznego rekordu wymiaru reprezentującego Związek Socjalistycznych Republik Radzieckich (ZSRR). Wymiar ten posiada kolumny śledzące czas życia rekordu (np. **ValidFrom**, **ValidTo**, **IsCurrent**), co pozwala ubezpieczycielowi analizować trendy ryzyka zgodnie z realiami geopolitycznymi i demograficznymi z momentu wystąpienia zdarzenia.

Architektura rozwiązania

System zbudowany jest w oparciu o klasyczną czterowarstwową architekturę hurtowni danych.



Warstwa 1 – Źródła danych

USGS dostarcza parametrów fizycznych zdarzeń sejsmicznych (czas, współrzędne, głębokość, magnituda), EMDAT uzupełnia je o dane humanitarne i ekonomiczne. Zbiory pozostają w relacji wiele-do-wielu: jeden rekord EMDAT może odpowiadać wielu zdarzeniom USGS (wstrząsy wtórne), a większość rekordów USGS nie ma odpowiednika w EMDAT ze względu na kryterium włączenia (min. 10 ofiar).

Warstwa 2 – ETL

Proces ETL realizowany w SSIS przebiega dwuetapowo: najpierw surowe dane trafiają do bazy stagingowej bez transformacji, następnie wykonywane są walidacja zakresów atrybutów, ujednolicenie kodów krajów do ISO 3166-1 alfa-3, filtrowanie zdarzeń niebędących trzęsieniami ziemi oraz przestrzenno-czasowe dopasowanie rekordów EMDAT do USGS. Transformacje obejmują również generację kluczy zastępczych (surrogate keys) oraz obsługę logiczną wymiaru DimGeography zgodnie z logiką SCD2.

Warstwa 3 – Hurtownia danych

Schemat konstelacji faktów (Fact Constellation), opisany szerzej w sekcji 2.3, pozwala na elastyczne przepytывanie bazy zarówno pod kątem surowych zdarzeń sejsmicznych, jak i wynikających z nich katastrof. Mostkowa tabela relacyjna gwarantuje uniknięcie

duplikacji miar addytywnych, takich jak liczba ofiar czy koszty finansowe.

Warstwa 4 – Raportowanie BI

Power BI w trybie Import, połączony bezpośrednio z hurtownią. Dashboardy obejmują mapę epicentrów, analizę trendów czasowych, ranking krajów według strat oraz korelację magnitudy ze skutkami. Model uwzględnia dwukierunkowe filtrowanie (cross-filtering) na tabeli mostkowej.

Stack technologiczny

Warstwa	Technologia
Pozyskiwanie danych	Python 3.x + biblioteki <code>requests</code> i <code>pandas</code>
ETL / Staging	SSIS (SQL Server Integration Services)
Hurtownia danych	Microsoft SQL Server 2019+
Warstwa OLAP	SQL Server Analysis Services (SSAS)
Raportowanie	Power BI