


1. Model Fizyczny Hurtowni Danych

Model hurtowni zbudowany jest w schemacie konstelacji faktów (Fact Constellation) zoptymalizowanym dla środowiska Microsoft SQL Server. Wybór tego schematu, zamiast klasycznej gwiazdy, podyktowany był asymetryczną relacją oraz różnicą w ziarnistości obu źródeł danych: nie każde trzęsienie ziemi wywołuje katastrofę, a jedna katastrofa może być wynikiem wielu wstrząsów.

Centralnymi elementami systemu są dwie niezależne tabele faktów, wokół których zbudowano dedykowane wymiary, połączone za pomocą wspólnych wymiarów konformowalnych oraz elastycznej tabeli mostkowej. Całość ekosystemu można podzielić na następujące filary:

- **Wymiary Konformowalne (Wspólne):** Tabele `DimDate` oraz `DimGeography` pełnią rolę fundamentu spajającego model. Pozwalają one na jednoczesne filtrowanie i analizowanie danych z obu tabel faktów w jednym widoku (np. zestawienie łącznej siły wstrząsów w danym roku i kraju z całkowitymi stratami finansowymi z tego samego okresu).
- **Wymiary Dziedzinowe:** Specyficzne dla danego faktu tabele kategoryzujące, takie jak `DimMagnitude` i `DimSeismicDepth` (opisujące parametry fizyczne), oraz `DimSeverityDeaths` i `DimSeverityAffected` (klasyfikujące skalę tragedii ludzkiej).
- **FactSeismic:** Niskopoziomowa tabela faktów o dużej ziarnistości. Gromadzi surowe, fizyczne parametry zdarzeń sejsmicznych rejestrowane przez United States Geological Survey (USGS) z dokładnością do konkretnego punktu geograficznego i sekundy.
- **FactDisaster:** Zagregowana tabela faktów o niższej ziarnistości. Gromadzi informacje o konsekwencjach humanitarnych i ekonomicznych trzęsień ziemi, pochodzące z bazy Emergency Events Database (EMDAT), stanowiąc biznesowy obraz szkód rozliczanych przez ubezpieczycieli.
- **BridgeDisasterSeismic:** Tabela bezfaktowa (factless bridge table) rozwiązująca skomplikowaną relację wiele-do-wielu (M:N) pomiędzy wstrząsami fizycznymi a ostatecznymi szkodami. Jej zastosowanie jest kluczowe dla uniknięcia błędów duplikacji miar addytywnych (np. wielokrotnego zliczania tych samych ofiar przy przypisywaniu ich do wstrząsów wtórnych).



Rysunek 1: Diagram modelu fizycznego Entity-Relationship (ERD)

2. Słownik Danych - Struktura Tabel

Poniżej przedstawiono szczegółową strukturę wszystkich obiektów w modelu bazy danych. Wszystkie tabele posiadają standardowe metadane audytowe (*InsertDate*, *UpdateDate*).

2.1 Tabele Wymiarów

Tabela: DimDate

Wymiar czasu na poziomie pojedynczego dnia. Obie tabele faktów łączone są z tym wymiarem przez spłaszczony klucz YYYYMMDD (wstrząsy USGS mapowane są na datę wystąpienia bo w źródle danych czas zdarzeń sejsmicznych jest podawany co do sekundy).

Kolumna	Typ	Wymagane	Opis
DateKey (PK)	INT	TAK	Klucz zastępczy (YYYYMMDD)
Date	DATE	TAK	Pełna data rekordu
Year	SMALLINT	TAK	Rok kalendarzowy
Quarter	TINYINT	TAK	Kwartał (1-4)
Month	TINYINT	TAK	Miesiąc (1-12)
MonthName	NVARCHAR(15)	TAK	Pełna nazwa miesiąca
MonthNameShort	CHAR(3)	TAK	Skrócona nazwa miesiąca (np. Sty)
Day	TINYINT	TAK	Dzień miesiąca
DayWeek	TINYINT	TAK	Numer dnia tygodnia (1-7)
DayWeekName	NVARCHAR(10)	TAK	Nazwa dnia tygodnia
DayYear	SMALLINT	TAK	Dzień w roku
WeekYear	TINYINT	TAK	Numer tygodnia wg normy ISO
InsertDate	DATETIME	TAK	Data wstawienia rekordu (ETL)
UpdateDate	DATETIME	TAK	Data ostatniej aktualizacji (ETL)

Tabela: DimGeography (SCD Typ 2)

Wymiar geograficzny obsługujący historyczność zmian granic i nazw państw (SCD2). W przypadku USGS z danych geograficznych podane są jedynie współrzędne więc przynależność wstrząsu do kraju wyznaczana jest przez ich odwrotne geokodowanie. Wstrząsy na wodach międzynarodowych otrzymują kod ISO "XIN". W przypadku EMDAT państwo mamy podane bezpośrednio jako kolumnę.

Kolumna	Typ	Wymagane	Opis
GeographyKey (PK)	INT	TAK	Klucz zastępczy (surogat)
CountryName	NVARCHAR(100)	TAK	Pełna nazwa kraju; atrybut podlegający śledzeniu SCD2
ISO	CHAR(3)	TAK	Kod kraju wg ISO 3166-1 alpha-3
SubRegion	NVARCHAR(50)	TAK	Podregion wg klasyfikacji UN M49
Region	NVARCHAR(25)	TAK	Region wg klasyfikacji UN M49
ValidFrom	DATE	TAK	Pocz. okresu ważności wersji wiersza
ValidTo	DATE	NIE	Koniec okresu ważności wersji wiersza
IsCurrent	BIT	TAK	Flaga bieżącej wersji rekordu (1 = aktywny)
GeoSeismicZone	NVARCHAR(20)	NIE	Strefa zagrożenia sejsmicznego wyliczona na podstawie GEM
GEM_PGA_g	DECIMAL(4,3)	NIE	Średnia wartość przyspieszenia gruntu PGA (Peak Ground Acceleration)

CountryDurableKey	INT	TAK	Trwały klucz biznesowy, niezmienny mimo zmian historycznych w nazwie kraju
InsertDate	DATETIME	TAK	Data wstawienia rekordu (ETL)
UpdateDate	DATETIME	TAK	Data ostatniej aktualizacji (ETL)

Tabela: DimMagnitude

Wymiar grupujący dokładne odczyty siły wstrząsów (magnitudy) w szersze pasma w celu łatwiejszej kategoryzacji na poziomie raportów.

Kolumna	Typ	Wymagane	Opis
MagnitudeKey (PK)	SMALLINT	TAK	Klucz zastępczy pasma
BandCode	NVARCHAR(5)	TAK	Kod pasma (np. M5-6)
BandName	NVARCHAR(10)	TAK	Słowny opis pasma (np. Strong)
LowerBound	DECIMAL(4,2)	TAK	Dolna granica pasma (włącznie)
UpperBound	DECIMAL(4,2)	TAK	Górna granica pasma (wyłącznie)
MagScale	NVARCHAR(3)	TAK	Skala pomiarowa stosowana przez źródło (np. Mw, Ml)
InsertDate	DATETIME	TAK	Data wstawienia rekordu (ETL)
UpdateDate	DATETIME	TAK	Data ostatniej aktualizacji (ETL)

Tabela: DimSeismicDepth

Wymiar przyporządkowujący dokładną głębokość wstrząsu do klasyfikacji sejsmicznej (np. wstrząsy płytkie, pośrednie, głębokie).

Kolumna	Typ	Wymagane	Opis
SeismicDepthKey (PK)	TINYINT	TAK	Klucz zastępczy pasma głębokości
BandName	NVARCHAR(15)	TAK	Opis pasma (Shallow, Intermediate, Deep)
LowerBoundKM	INT	TAK	Dolna granica głębokości w kilometrach
UpperBoundKM	INT	TAK	Górna granica głębokości w kilometrach
InsertDate	DATETIME	TAK	Data wstawienia rekordu (ETL)
UpdateDate	DATETIME	TAK	Data ostatniej aktualizacji (ETL)

Tabela: DimSeverityDeaths

Wymiar oceniający skalę tragedii na podstawie przyporządkowania liczby ofiar śmiertelnych do określonego koszyka (Low, Medium, High, Catastrophic).

Kolumna	Typ	Wymagane	Opis
SeverityDeathsKey (PK)	TINYINT	TAK	Klucz zastępczy kategorii strat w ludziach
SeverityCode	NVARCHAR(15)	TAK	Kod klasy ciężkości
LowerBound	INT	TAK	Dolny limit przedziału liczby ofiar
UpperBound	INT	TAK	Górny limit przedziału (NULL dla najwyższego)
InsertDate	DATETIME	TAK	Data wstawienia rekordu (ETL)
UpdateDate	DATETIME	TAK	Data ostatniej aktualizacji (ETL)

Tabela: DimSeverityAffected

Wymiar oceniający skalę katastrofy na podstawie całkowitej liczby poszkodowanych.

Kolumna	Typ	Wymagane	Opis
SeverityAffectedKey (PK)	TINYINT	TAK	Klucz zastępczy kategorii poszkodowanych
SeverityCode	NVARCHAR(15)	TAK	Kod klasy ciężkości
LowerBound	INT	TAK	Dolny limit przedziału liczby poszkodowanych
UpperBound	INT	TAK	Górny limit przedziału
InsertDate	DATETIME	TAK	Data wstawienia rekordu (ETL)
UpdateDate	DATETIME	TAK	Data ostatniej aktualizacji (ETL)

2.2 Tabele Faktów

Tabela: FactSeismic

Granulacja: jeden wiersz odpowiada jednemu fizycznemu zdarzeniu sejsmicznemu zarejestrowanemu w strumieniu danych USGS.

Kolumna	Typ	Wymagane	Opis
SeismicKey (PK)	BIGINT	TAK	Klucz zastępczy faktu
DateKey (FK)	INT	TAK	Odniesienie do daty wystąpienia wstrząsu
GeographyKey (FK)	INT	TAK	Odniesienie do zidentyfikowanego państwa
MagnitudeKey (FK)	SMALLINT	TAK	Odniesienie do wymiaru pasma siły wstrząsu
SeismicDepthKey (FK)	TINYINT	TAK	Odniesienie do wymiaru głębokości
Latitude	DECIMAL(8,5)	TAK	Szerokość geograficzna epicentrum
Longitude	DECIMAL(9,5)	TAK	Długość geograficzna epicentrum
Magnitude	DECIMAL(4,2)	TAK	Precyzyjna wartość magnitudy
SeismicDepth	DECIMAL(7,2)	TAK	Głębokość hipocentrum wyrażona w kilometrach
ModifiedMercalliIntensity	DECIMAL(4,2)	NIE	Ocena intensywności odczuwania wstrząsu (skala MMI)
SignificanceScore	INT	NIE	Syntetyczny algorytmiczny wskaźnik ważności USGS
CommunityDecimalIntensity	DECIMAL(3,1)	NIE	Intensywność skalkulowana na bazie zgłoszeń ludności
InsertDate	DATETIME	TAK	Data wstawienia rekordu (ETL)
UpdateDate	DATETIME	TAK	Data ostatniej aktualizacji (ETL)

Tabela: FactDisaster

Granulacja: jeden wiersz odpowiada jednej zgłoszonej katastrofie (o typie "Earthquake") w bazie EM-DAT. Tabela przechowuje metryki ostatecznych strat dla całego incydentu, niezależnie od liczby wstrząsów fizycznych, które się do niego przyczyniły.

Kolumna	Typ	Wymagane	Opis
DisasterKey (PK)	INT	TAK	Klucz zastępczy faktu katastrofy
StartDate (FK)	INT	TAK	Data początkowa wystąpienia skutków
EndDate (FK)	INT	TAK	Data zakończenia rejestracji zdarzenia
GeographyKey (FK)	INT	TAK	Zgłoszony kraj wystąpienia szkód

Kolumna	Typ	Wymagane	Opis
SeverityDeathsKey (FK)	TINYINT	TAK	Pasmo klasyfikacji katastrofy wg ofiar
SeverityAffectedKey (FK)	TINYINT	TAK	Pasmo klasyfikacji wg poszkodowanych
Latitude	DECIMAL(8,5)	NIE	Geograficzny centroid obszaru katastrofy
Longitude	DECIMAL(9,5)	NIE	Długość geograficzna centroidu
DurationDays	INT	NIE	Obliczony czas trwania katastrofy w dniach
TotalDeaths	INT	TAK	Łączna liczba ofiar śmiertelnych
TotalAffected	INT	NIE	Całkowita liczba osób poszkodowanych
NumInjuries	INT	NIE	Osoby z obrażeniami ciała
NumOtherAffected	INT	NIE	Inne osoby dotknięte zdarzeniem
NumHomeless	INT	NIE	Osoby, które straciły miejsce zamieszkania
TotalDamage	BIGINT	NIE	Szacowane łączne straty materialne (w USD z uwzględnieniem inflacji)
InsuredDamage	BIGINT	NIE	Wartość strat pokrytych z polis ubezpieczeniowych
Tsunami	BIT	TAK	Flaga (0/1) potwierdzająca uderzenie fali tsunami
InsertDate	DATETIME	TAK	Data wstawienia rekordu (ETL)
UpdateDate	DATETIME	TAK	Data ostatniej aktualizacji (ETL)

Uwaga do miar w FactDisaster: TotalAffected może być wartością większą niż prosta suma unikalnych osób, ponieważ baza źródłowa pozwala na przynależność jednej osoby do wielu kategorii skutków (np. ranny oraz bezdomny jednocześnie).

Tabela: BridgeDisasterSeismic

Tabela bezfaktowa (mostkowa) spajająca rozłączne zbiory danych USGS i EMDAT. Przechowuje logikę dopasowania i oceny odległości wstrząsu od zaistniałej katastrofy.

Kolumna	Typ	Wymagane	Opis
DisasterKey (PK, FK)	INT	TAK	Odniesienie do rekordu w tabeli FactDisaster
SeismicKey (PK, FK)	BIGINT	TAK	Odniesienie do powiązanego wstrząsu w FactSeismic
DistanceKM	DECIMAL(6,3)	NIE	Dystans między epicentrum a centroidem w km
TimeLagDays	SMALLINT	NIE	Opóźnienie (w dniach) między trzęsieniem a początkiem katastrofy
InsertDate	DATETIME	TAK	Data wstawienia rekordu (ETL)
UpdateDate	DATETIME	TAK	Data ostatniej aktualizacji (ETL)

3. Kluczowe Miary i Atrybuty

3.1 Miary (Measures)

Nazwa miary	Formuła/opis	Tabela źródłowa
Liczba wstrząsów	COUNT(Seismickey)	FactSeismic

Średnia magnituda	AVG(Magnitude)	FactSeismic
Maks. magnituda	MAX(Magnitude)	FactSeismic
Średnia głębokość	AVG(SeismicDepth)	FactSeismic
Średnie MMI	AVG(ModifiedMercalliIntensity)	FactSeismic
Liczba katastrof	COUNT(DisasterKey)	FactDisaster
Łączne ofiary	SUM(TotalDeaths)	FactDisaster
Łączni poszkodowani	SUM(TotalAffected)	FactDisaster
Straty materialne	SUM(TotalDamageAdj)	FactDisaster
Straty ubezpieczone	SUM(InsuredDamage)	FactDisaster
Wskaźnik ubezpieczenia [%]	SUM(InsuredDamage) / SUM(TotalDamageAdj) x 100	FactDisaster
Różnica straty vs ubez.	SUM(TotalDamageAdj) - SUM(InsuredDamage)	FactDisaster
Liczba katastrof z tsunami	COUNT(DisasterKey) WHERE Tsunami = 1	FactDisaster
Śr. czas trwania katastrofy	AVG(DurationDays)	FactDisaster
Wstrząsów na katastrofę	COUNT(Seismickey) / COUNT(DISTINCT DisasterKey)	BridgeDisasterSeismic
Śr. odległość wstrząs-katastrofa	AVG(DistanceKM)	BridgeDisasterSeismic

4. Opis Logiki Procesu ETL

Proces zasilania hurtowni danych (Extract, Transform, Load) zaprojektowano przy użyciu SQL Server Integration Services (SSIS), a za jego cykliczne uruchamianie i monitorowanie odpowiada SQL Server Agent. Architektura strumienia danych została logicznie podzielona na obsługę dwóch niezależnych dostawców danych z wykorzystaniem obszaru przejściowego (Staging).

4.1 Ekstrakcja Danych Sejsmicznych (Zbiór USGS)

Proces pobierania danych o aktywności sejsmicznej cechuje się dużą częstotliwością i odbywa się za pośrednictwem żądań API.

- System wykorzystuje skrypty Python do łączenia się z REST API organizacji USGS.
- Ekstrakcja działa w trybie przyrostowym (inkrementalnym), bazując na dacie ostatniego poprawnego zakończenia pobierania do chwili obecnej.
- Pobrany plik CSV trafia do lokalnego obszaru ładowania (landing zone), a dane przed obróbką poddawane są wyczyszczeniu tabeli przejściowej (**TRUNCATE**) w celu uniknięcia duplikacji wsadów przed głównym etapem ładowania.

4.2 Ekstrakcja Danych o Szkodach (Zbiór EMDAT)

Informacje dotyczące katastrof (ofiary, zniszczenia infrastrukturalne) aktualizowane są rzadziej (zwykle w cyklu tygodniowym), na podstawie eksportu z oficjalnego portalu. Pobierane są wyłącznie te zdarzenia, w których głównym czynnikiem niszczącym zdefiniowano trzęsienie ziemi (typ: Earthquake).

4.3 Integracja i Transformacja Danych (Zasady Biznesowe)

Na ścieżce pomiędzy warstwą staging a docelowymi tabelami faktów w hurtowni, dane przechodzą przez filtry czyszczące oraz szereg złożonych modyfikacji i asercji:

- **Walidacja geolokalizacji:** Rekordy z USGS weryfikowane są pod kątem poprawności współrzędnych i parametrów. Błędne wiersze izolowane są w odrębnej tabeli odrzutów.

- **Wzbogacenie geograficzne i dane GEM:** Zastosowano geokodowanie odwrotne, aby przypisać fizyczny wstrząs do terytorium państwa wg słownika ISO (wstrząsy na oceanach otrzymują kod "XIN"). Co istotne, profil kraju w wymiarze **DimGeography** wzbogacany jest z zewnętrznego, statycznego pliku referencyjnego dostarczanego przez fundację **GEM (Global Earthquake Model)**. Na podstawie kodu ISO dołączane są wskaźniki **GEM_PGA_g** oraz przydział do odpowiedniej strefy **GeoSeismicZone**.
- **Logika SCD Typ 2 (Wolnozmienniający się Wymiar):** Kody państw przesyłane ze źródeł wyzwalają mechanizm detekcji zmian (Delta Detection) w tabeli **DimGeography**.
 - Jeżeli w danych napływających zmieni się np. nazwa państwa (atrybut **CountryName**), a kod identyfikacyjny **CountryDurableKey** pozostaje ten sam, system zamyka starą wersję rekordu (ustawiając w niej **ValidTo** na dzień wczorajszy i flagę **IsCurrent=0**).
 - Następnie tworzony jest nowy wiersz (z nowym **GeographyKey**, **ValidFrom** ustawionym na dziś oraz **IsCurrent=1**).
 - Tabele faktów realizują procedurę *Lookup* z bezwzględnym warunkiem **IsCurrent=1**, co oznacza, że nowo ładowane wstrząsy i katastrofy są zawsze przypisywane do bieżących realiów geopolitycznych państwa.
- **Strategia zarządzania wartościami Null (FactDisaster):** Ze względu na specyfikę bazy EMDAT, proces ETL wdraża rygorystyczną logikę obsługi brakujących danych liczbowych. Kluczowym wskaźnikiem warunkującym jest tu zmienna **TotalAffected**.
 - Jeśli dla danej katastrofy **TotalAffected IS NULL** (brak jakichkolwiek szacunków poszkodowanych), kolumny składowe (**NumInjuries**, **NumOtherAffected**, **NumHomeless**) są bezwzględnie ustawiane na **NULL**, aby nie zaburzać średnich analitycznych fałszywymi zerami.
 - Jeśli jednak **TotalAffected IS NOT NULL** (nawet jeśli wynosi 0), brakujące wartości w kolumnach składowych (**Num***) są wymuszane na **0**. Zapobiega to błędom matematycznym podczas analizy składowych katastrofy.

4.4 Generowanie Wpisów w Tabeli Mostkowej

Aby analitycy mogli prowadzić badania przyczynowo-skutkowe, na zakończenie każdego cyklu zasilania wyzwalana jest dedykowana procedura składowana łącząca wstrząsy z katastrofami.

- Algorytm iteruje nad każdą katastrofą z bazy EMDAT i weryfikuje kandydatów z bazy USGS stosując zdefiniowane warunki w oknie czasowym (wstrząs przed rozpoczęciem katastrofy, atrybut **TimeLagDays**) oraz przestrzeni (odległość w promieniu weryfikowana algorytmem Haversine, atrybut **DistanceKM**).
- **Ograniczenie dla zdarzeń EMDAT bez współrzędnych:** Warto zaznaczyć, że około 4% historycznych rekordów w bazie EMDAT nie posiada precyzyjnie oznaczonych współrzędnych geograficznych (**Latitude/Longitude** są **NULL**). Dla tych specyficznych rekordów algorytm mapowania przestrzennego w tabeli mostkowej zostaje pominięty. Zdarzenia te trafiają do bazy ze statusem niezmapowanym na poziomie epicentrum, pozostając połączone jedynie przez wymiar daty i ogólnego kraju (**DimGeography**).

5. Planowane raporty

Warstwa raportowa zbudowana jest w środowisku Power BI na podstawie wielowymiarowego modelu semantycznego osadzonego bezpośrednio nad hurtownią. Dzięki temu wszystkie obszary biznesowe (Aktuariat, Underwriting, Ocena Ryzyka) pracują na ustandaryzowanych miarach.

Raport	Odbiorca	Cel analityczny
Mapa epicentrów sejsmicznych	Analitik ryzyka	Wizualizacja przestrzennego rozkładu wstrząsów z filtrami magnitudy, głębokości i okna czasowego.
Ranking krajów wg strat	Aktuariusz, zarząd	Zestawienie państw generujących największe wartości TotalDamageAdj oraz InsuredDamage.
Korelacja magnituda skutki	Aktuariusz	Analiza zależności między punktową magnitudą wstrząsu a fizyczną skalą zniszczeń i ofiar na poszczególnych rynkach ubezpieczeniowych.
Trendy roczne / dekadowe	Zarząd, analitik ryzyka	Długoterminowa analiza zmienności w częstości występowania zdarzeń a kosztami ubezpieczyciela ujętymi na linii czasu.
Profil ryzyka per kraj	Reasekurator, underwriter	Syntetyczna karta oceny kraju uwzględniająca historyczne dane obciążeń, przynależność do GeoSeismicZone oraz referencyjne współczynniki wstrząsów przyspieszeń z instytutu GEM.
Tsunami history	Specjalista ds. produktu	Geoprzestrzenna ocena historycznego zasięgu strat i katastrof spotęgowanych zjawiskami wtórnymi (powodzie nadmorskie z uderzenia fali).
Strefa GEM vs realizacja strat	Analitik ryzyka	Modelowa walidacja założeń taryfikacyjnych: czy odnotowane straty materialne układają się w obszarach wytypowanych wcześniej teoretycznie w oparciu o GEM.
Luka Ubezpieczenia	Aktuariusz, zarząd	Stosunek ubezpieczonego do zniszczonego mienia per region - identyfikacja penetracji rynku i docelowych regionów sprzedażowych.
Profil Wstrząsów Wtórnych	Underwriter	Analiza wykorzystująca tabelę mostkową do zbadania stopnia degradacji infrastruktury uzależnionej od nasilenia dodatkowych zdarzeń.
Mapa Opóźnień Czasowych	Specjalista ds. likwidacji szkód	Analiza dynamiki kryzysu pokazująca średni czas między uderzeniem pierwszej fali sejsmicznej a wejściem zgłoszenia i momentem formalnego otwarcia procedur w bazie katastrof.
Wstrząsy Transgraniczne	Menedżer ds. Ryzyka Kumulacji	Rozkład strat dla trzęsień, które równolegle naruszyły limity wielu oddziałów krajowych.
Drill-Through Złożoności Zdarzenia	Analitik ryzyka, Underwriter, Reasekurator	Kontekstualne widoki wglądne detali wstrząsów fizycznych przypisanych pod konkretny rekord straty w EMDAT.